

教程1：如何不写代码训练AI模型

在已知的数据中学习规律从而建立模型，并且借助更多的数据自动修正、优化模型，最终利用模型解决问题的AI研究方法叫做“机器学习”。机器学习实际上分为两个阶段：在已知数据中学习规律，叫做“模型训练”，即“学习”；将新的数据输入到模型中得出结果，叫做“模型推理”，即“应用”，如图1所示。这个过程和人、动物的学习是一致的。


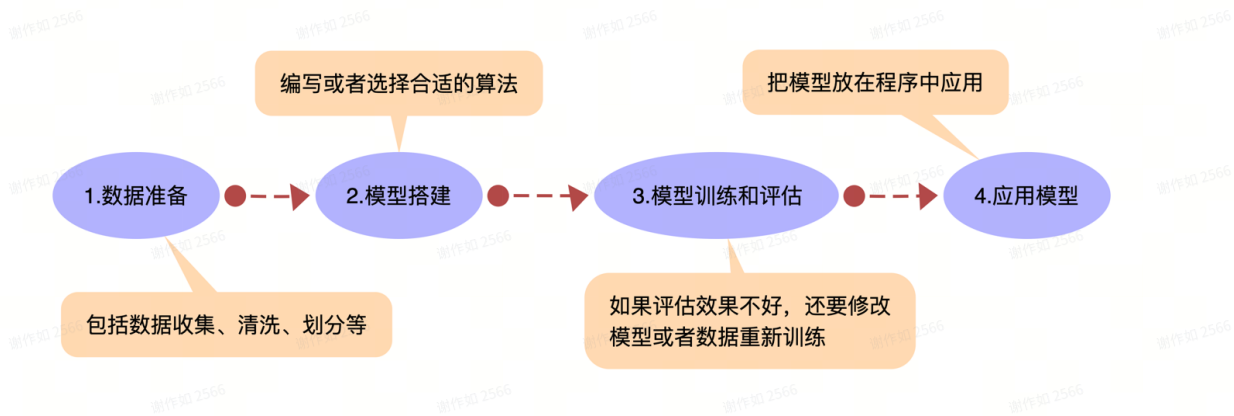


图1 人工智能模型的训练和推理

所有的模型训练工作大致可以分为数据准备、模型搭建、模型训练、模型评估等核心环节，如图2所示。因此，从工作流程看，训练AI模型的难度在数据准备和算法搭建，而训练的速度则决定于算力。只要找到合适的工具，训练常见的AI模型并不困难。如同要旋松一个螺帽，没有相应的工具（钢丝钳、扳手、套筒等）会很难，徒手更是难上加难。随着技术的发展，越来越多的AI开发工具出现，不写代码（无代码）或者仅仅写少量的代码（少代码）就能训练简单的模型。为了表述方便，下面统一用“无代码”指代不写代码和仅仅写少量的代码。



一、无代码训练AI模型的技术路径分析

无代码训练模型的工具很多，比如浦育平台、ModelArts、MaixHub和EasyTrain等。实际上在大语言模型的支持下，通过合适的提示词，就能得到直接可用的模型训练代码。但不管通过哪种方式，实际上都是先要生成代码然后训练，只不过有些工具把生成的代码“隐藏”罢了。因此，训练模型始终需要部署底层的AI开发框架。

1.工具介绍——AI模型开发框架知多少

在AI领域，有多种模型开发框架供开发者选择。大部分编程语言都支持机器学习和深度学习，其中Python是最常用的一种。Python中有许多传统机器学习库，如scikit-learn、SciPy和BaseML等。随着神经网络算法的兴起，又出现了如TensorFlow、PyTorch和PaddlePaddle等框架。为了区分，本文将机器学习分为“传统机器学习”和“深度学习”来介绍。

1) 传统机器学习类

(1) Scikit-learn。Scikit-learn是一个开源的机器学习库，支持监督学习和无监督的学习。它还提供了用于模型拟合、数据预处理、模型选择、模型评估和各种其他实用程序的工具。scikit-learn内置了很多算法模型，可以很方便地调用。以搭建线性回归模型并训练为例，核心代码如下所示。

```
1 from sklearn.linear_model import LinearRegression # 从库中导入线性回归模块
2 from sklearn.model_selection import train_test_split # 从库中导入数据划分模块
3 model = LinearRegression() # 实例化一个线性回归模型
4 '''
5 省略从scv中读取数据到变量x、y中。
6 '''
7 X_train, X_valid, y_train, y_valid = train_test_split(X, y, random_state=0) # 将
  数据拆分为训练集和验证集
8 my_model = model.fit(X_train, y_train) # 训练模型
```

(2) BaseML是上海人工智能实验室开发的“XEdu”（可以看成是一个工具箱）中的一款子工具，针对scikit-learn做了进一步的封装，只需几行代码就能实现机器学习模型的训练或应用。比如一个线性回归的模型训练代码如下所示。

```
1 from BaseML import Regression as reg # 从库文件中导入回归任务模块
2 model = reg('LinearRegression') # 实例化线性回归模型
3 model.load_tab_data('data_train.csv') # 载入训练数据
4 model.train() # 训练模型
5 model.valid('data_val.csv', metrics='r2') # 载入验证数据并验证
6 model.save('mymodel.pkl') # 保存模型供应用
```

第一行代码是根据机器学习的任务导入相应的库，“Regression”模块内置了回归任务的常见算法。第二行是实例化一个模型对象，“model = reg('LinearRegression')”表示指定的算法是“LinearRegression”（线性回归）。用“load_tab_data”方法载入数据集后，用“train”开始训练模型。

使用“load_tab_data”，即可加载CSV格式的数据文件。这里要求数据文件每行一条记录（首行为表头，数据从第2行开始），输入数据（特征）列在前，输出数据（目标或标签）列在后，即最后一列为输出数据，其余列为输入数据，以CSV格式存储。这种格式是最常见的监督学习数据格式，如图3所示。如果数据集和这种格式不一致，则需要用“load_dataset”的方法，这种方法可以更加灵活地载入数据。

	A	B	输入数据	D	E	输出数据
1	feature1	feature2	feature3	feature4	feature5	Label
2	-1	52	36	59	6.5	155
3	1	70	41	65	8.5	170
4	-1	68	39	64	8.3	168
5	-1	56	38	61	7	160
6	1	62	43	70	8.5	185
7	1	55	43	61	6.8	160
8	-1	57	38	64	7.1	168
9	1	50	41	65	7.8	170
10	-1	65	39	61	7.6	160
11	-1	61	39	60	6.8	159
12	1	70	44	71	8.8	188
13	1	52	40	66	7.6	173
14	1	72	42	68	8.9	180
15	1	67	44	70	8.4	183
16	-1	52	37	64	6.7	168
17	1	70	43	69	7.9	167

图3 “load_tab_data” 直接支持的数据集格式

model.load_dataset(data_path,type,x_column,y_column,split,shuffle,scale,show)函数中有许多参数，这里分别介绍：

- type：表示X和y的输入格式，可选项为 ‘csv’、 ‘numpy’、 'pandas'、 'list'、 'txt'，如type='csv'。
- x_column：表示特征列，如x_column=[1,2,3,4]。
- y_column：表示标签列，如y_column=[5]。
- split：是否划分训练集、验证集，默认为True。
- shuffle：是否打乱数据，默认为True。
- scale：是否对数据进行归一化，默认为False。
- show：显示5条数据。默认为True。

2) 深度学习类

Tensorflow和PyTorch是迄今为止最受欢迎的两个AI开发框架，都拥有丰富的API、广阔的用户群体，目前也都广泛用于学术研究和商业应用。因为Keras的出现，简化了TensorFlow的开发门槛，更适合初学者。但是Pytorch也支持Keras，并且出现了FastAI以及OpenMMLab之类的工具，同样拥有大量的用户，常见工具如表1所示。

表1 常见的深度学习开发工具（框架）

名称	开发团队	发布时间	功能特点
TensorFlow	谷歌	2015	是很多人进入人工智能领域第一个听到或者接触的开发框架。
Keras	谷歌	2015	Keras则在TensorFlow的基础上发展起来，开发门槛更低，拥有大量的用户。可以把看成是TensorFlow的入门简化版本。
PyTorch	Facebook	2017	PyTorch用于张量计算、自动微分和 GPU加速，深受科研人员的喜好。
飞桨 (PaddlePaddle)	百度	2016	集核心框架、基础模型库、端到端开发套件、丰富的工具组件、用户社区于一体，是中国首个自主研发、功能丰富、开源开放的产业级深度学习平台。

2022年12月，上海人工智能实验室浦育团队发布了开箱即用的深度学习开发工具MMedu，引起了中小学教育领域的关注。随后，浦育团队又相继发布了BaseML、BaseNN和XEduhub等工具，与MMedu合并为XEdu，成为中小学生学习人工智能的必备工具之一。

需要强调的是，谷歌团队在TensorFlow之后发布了TensorFlow.js。借助TensorFlow.js，通过浏览器也能过训练一些简单的模型。浦育平台上借助网页训练模型的，大部分基于TensorFlow.js来实现。但是这种方式训练出来的模型，需要借助第三方工具才能转换为通用的ONNX模型。目前，浦育平台只有“图像分类”模型才可以转换为ONNX。

2.路径分析——无代码训练模型的两种方式

考虑到工具的通用性，本教程选择XEdu的EasyTrain和大语言模型生成训练代码两种方式进行介绍。


1) 使用EasyTrain训练模型

EasyTrain是XEdu项目中“EasyDL”系列工具中的一种。顾名思义，就是用来做模型训练的小工具。EasyTrain支持MMedu、BaseNN和BaseML，能够在网页中生成模型训练代码，也能够能够在网页端调用底层框架的代码训练模型。

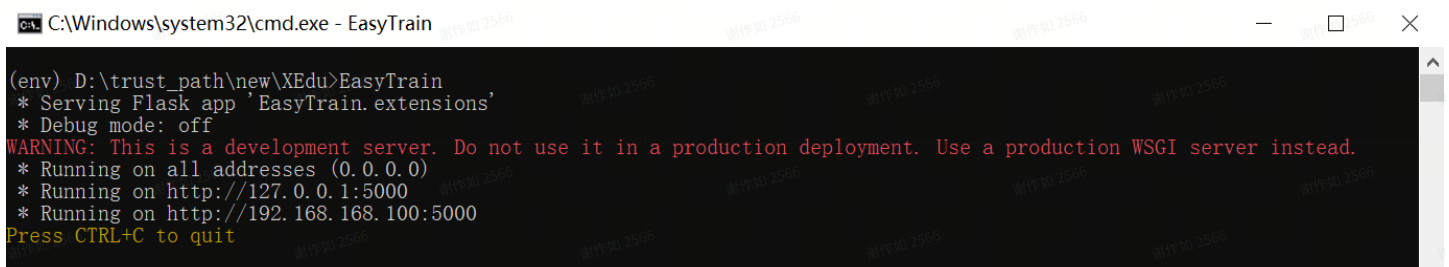


图4 EasyTrain的界面

那么如何获得并使用EasyTrain? 这里提供两种方式。第一种方式是使用“XEdu一键安装包”，其内置的EasyDL系列工具中有“EasyTrain.bat”，运行即可。



第二种方式是使用pip安装，使用命令“pip install easy-xedu>=0.2.2”进行安装，即可安装EasyTrain界面，在训练启动时，会自动检查所依赖的python环境，如果缺少对应环境，会给出提示（如运行BaseML生成的代码需要安装BaseML，命令为“pip install BaseML”）。启动EasyTrain同样也是使用指令来完成，命令为“EasyTrain”。



需要注意的是，EasyTrain基于Flask框架开发，要求计算机的用户名和计算机名称均不得出现中文，否则无法正常启动。

2) 大语言模型生成训练代码

经过测试，文心一言、商量、智谱清言、kimi等国产大语言模型，在代码生成方面效果很不错。如果要得到模型训练方面的代码，则需要明确使用什么工具（如Keras、Pytorch、PaddlePaddle等），要训练的是什么模型，实现什么功能等。要求越具体，得到的代码也会越准确。

因为XEdu是新开发的库，暂时没有加入到大语言模型的训练数据中，需要自行微调。但随着大语言模型的上下文容量加大，RAG（Retrieval-Augmented Generation，检索增强生成）成为一个重要的应用，即把文档嵌入到大语言模型中作为外部信息源。XEdu团队提供了一个基于“扣子”的大模型助手“XEdu小助手”，在kimi的基础上嵌入了文档。即将发布的“极狐驭码”也内置了“XEdu助手”。向“XEdu助手”提问，既可得到相应的回答，还能得到相关的参考项目链接。

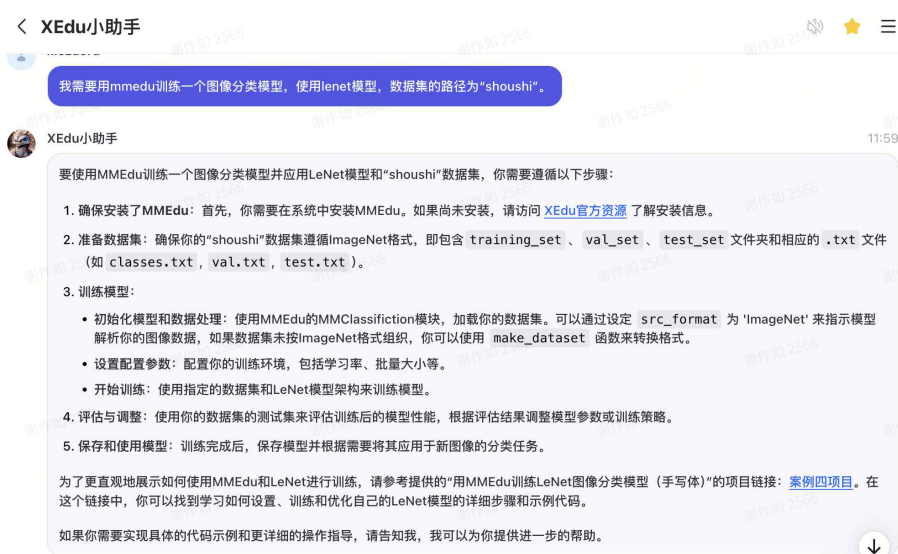


图5 “XEdu助手”的问答界面



图6 “XEdu助手”能给出具体的代码

同样，我们也需要关注大语言模型“胡说八道”的问题。在没有嵌入XEdu文档的情况下，如果问BaseNN、BaseML之类的问题，大语言模型可能会随便给出一个看起来像模像样的代码，其实是不能用的。

3.搭建环境——训练模型的准备工作

前面已经强调过，除了TensorFlow.js外，不管用哪一种无代码方式训练模型都需要相应的开发环境支持。搭建训练模型的环境，是最基础的准备工作。

1) 本地搭建环境

在本地安装AI模型训练环境，当然要借助pip工具来安装。这里不建议在原生的Python上安装，推荐使用Anconda之类的版本管理，也可以使用Docker镜像。

相对来说，最简单的方式是用“XEdu一键安装包”或者XEdu的Docker镜像。“XEdu一键安装包”中已经包含了Pytorch、MMEdU、BaseNN、BaseML、Scikit-learn等。

XEdu下载方式：<https://xedu.readthedocs.io/zh/master/about/installation.html>

从服务器端拉镜像的命令为：`docker pull xedu/xedu:v3s`

2) 云算力平台

云算力平台类似于远程的服务器。不管是哪一家云算力平台，也需要安装开发环境。Keras、Pytorch环境虽然比较常见，但因为版本较多往往也不太通用。目前有些云算力平台已经内置了XEdu环境，如浦育、Mo等。

Mo平台：<https://momodel.cn/>

OpenHydra：<https://openinnolab.org.cn/>

3) 私有云算力平台

有条件的学校可以购买带GPU的算力服务器或者工作站，自行部署环境。比如OpenHydra是一个支持算力分割（将一个算力设备发给多个用户）的开源人工智能教学平台。

二、不写代码训练AI模型的实例

受制于算力和工具，这里选择几个中小学中比较常用的AI模型进行介绍。需要再次强调的是，**使用大模型生成代码，也需要运行在合适的环境中**。因为XEdu已经内置了常见的环境，再次推荐使用。

1.传统机器学习的模型训练

虽然传统机器学习的算法很多，但Scikit-learn和BaseML中基本上都已经支持。不同的算法适合解决不同的任务。要用机器学习解决问题，首先要了解有哪些算法，并弄清楚这些算法擅长解决哪些

问题。为帮助初学者了解这些算法的作用，BaseML的文档中提供了一张《机器学习典型算法一览表》，节选如下。

表1 机器学习典型算法一览表节选

算法名称	适合任务	典型任务	算法解释
线性回归 (LinearRegression)	回归	适用于预测房价、预测销售额、贷款额度等。	就像用直尺在散点图上画一条尽可能穿过所有点的直线，这条直线就能帮我们预测未来的值。
多项式回归 (PolynomialRegression)	回归	适用于预测房价、预测销售额、贷款额度等。	就像是在一条直线上增加更多的弯曲，使得这条线可以更好地贴合数据点。就像用橡皮筋在散点图上拉出一个曲面，这个曲面就能更好地帮助我们预测未来的值。
支持向量机 (SVM)	分类/回归	能够很好地适应干扰数据和异常值带来的模型误差。适用于文本分类、图像识别等。	想象你有两种颜色的球分布在桌子上，SVM就是用一根棍子（在复杂情况下是一张弯曲的板）尽可能分开两种颜色的球。
决策树算法 (CART)	分类/回归	适用于客户分级、疾病诊断等。	想象你在做一个选择（比如选择餐馆），你可能会根据一系列问题（离家近不近？价格怎么样？）来决定。决策树算法就是通过一系列问题来达到决策的过程。

1) EasyTrain方式

EasyTrain支持BaseML。BaseML的代码很简洁，但是不同的算法可能有不同的训练参数，这些需要查文档，不需要死记硬背。

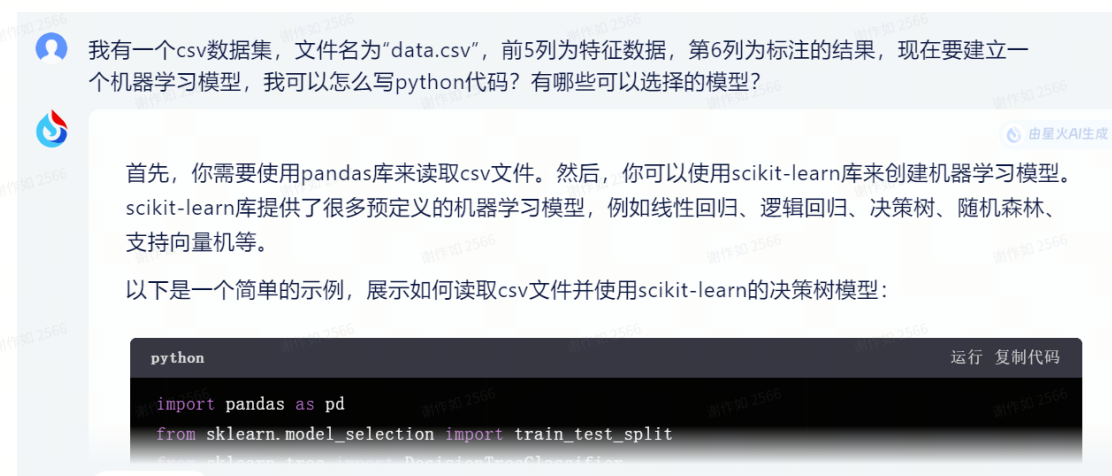






2) 大模型方式

向大模型“咨询”机器学习的训练代码，需要强调使用某一种算法。最好能明确描述数据集的细节，哪几列是特征，哪列是标签。以下图示是几种不同大语言模型的回答。





我有一个csv数据集，文件名为“data.csv”，前5列为特征数据，第6列为标注的结果，现在要建立一个机器学习模型，我以怎么写python代码？有哪些可以选择的模型？



为了建立一个机器学习模型来处理CSV数据集（例如“data.csv”），您首先需要加载数据，然后预处理数据（如果需要的话），接着分割数据为训练集和测试集，最后选择并训练一个机器学习模型。

以下是一个使用Python和scikit-learn库的基本步骤指南和示例代码：

步骤 1: 加载数据

python

复制代码

```
1 import pandas as pd
2
3 # 加载CSV文件
4 data = pd.read_csv('data.csv')
5
6 # 假设前5列是特征，第6列是标签
7 X = data.iloc[:, :-1] # 所有行，除了最后一列的所有列（即特征）
8 y = data.iloc[:, -1] # 所有行，最后一列（即标签）
```



我有一个csv数据集，文件名为“data.csv”，前5列为特征数据，第6列为标注的结果，现在要建立一个机器学习模型，我可以怎么写python代码？有哪些可以选择的模型？



要使用Python来处理CSV数据集并构建机器学习模型，你可以遵循以下步骤。这里以使用scikit-learn库为例，因为它提供了丰富的机器学习算法和工具。首先确保你已经安装了pandas和scikit-learn库，如果未安装，可以通过pip安装：

Bash

```
1 pip install pandas scikit-learn
```

1. 加载数据


首先，你需要加载CSV文件中的数据，并分割特征与目标变量。

Python

```
1 import pandas as pd
2
3 # 加载数据
4 data = pd.read_csv('data.csv')
5
6 # 假设前5列是特征，第6列是目标变量
```

2.全连接神经网络模型的训练

全连接神经网络是一种多层感知机构成的基本网络结构，可以处理更复杂的问题。随着隐藏层的增加，神经网络的非线性表达能力也将得到增强。全连接神经网络能同时适用于分类和回归任务，有点像“一招应万变”的必杀技。机器学习中也有个算法叫做多层感知机（MLP），其实就是全连接神经网络。




多层神经网络示意图

1) EasyTrain方式

EasyTrain支持BaseNN。用EasyTrain搭建全连接神经网络，有几个小诀窍。一是下一层输入维度和上一层输出维度要一致；二是激活函数可以都选择“ReLU”，最后一个选“SoftMax”，三是第一层输入维度是特征值数量，最后一层输出是分类的数量。





2) 大模型方式

向大模型“咨询”全连接神经网络的训练代码，需要明确使用哪一种框架，如Keras或者PaddlePaddle，也需要描述数据集的细节、路径，以及分类的数量，以确保生成的代码可以直接使用。当发现代码运行报错，要将错误信息发给大模型。大模型会根据错误反馈重新给出新的代码。

我想要用Keras搭建一个全连接神经网络来实现数据的分类任务，类别数量为3。数据集在“D:/mydata.csv”，数据以表格形式呈现，每行一条记录（首行为表头，数据从第2行开始），输入数据（特征）在前4列，输出数据（目标或标签）在第5列，以CSV格式存储。请帮我写一段这样的代码。

```
python
import pandas as pd
from keras.models import Sequential
from keras.layers import Dense
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder

# 读取数据
data = pd.read_csv("D:/mydata.csv")
X = data.iloc[:, 0:4].values
y = data.iloc[:, 4].values

# 对标签进行编码
encoder = LabelEncoder()
y = encoder.fit_transform(y)
```

我还希望把训练好的模型保存到“D:/files”，需要增加怎样的代码？以及如何使用保存下来的代码？

你可以使用Keras的`model.save()`方法来保存模型。以下是如何保存和加载模型的代码：

```
python
# 保存模型
model.save("D:/files/my_model.h5")

# 加载模型
from keras.models import load_model
loaded_model = load_model("D:/files/my_model.h5")
```

要使用保存下来的模型进行预测，你可以使用`loaded_model.predict()`方法。例如：

```
python
# 使用加载的模型进行预测
predictions = loaded_model.predict(X_test)
```

3.图像分类模型的训练


图像分类是深度学习中最常见的计算机视觉任务，核心算法为卷积神经网络。卷积神经网络由图灵奖获得者杨·立昆（Yann LeCun）教授提出，随后在各方面广泛应用。2012年辛顿团队夺冠的AlexNet，则是卷积神经网络的代表作之一。经过多年发展，除了图像处理之外，语音识别、自然语言处理等领域也都离不开卷积神经网络。

1) EasyTrain方式

EasyTrain支持MMEdU。MMEdU的分类任务在数据集上有限制条件，仅仅支持标准的ImageNet。需要安装ImageNet格式制作数据集，然后即可使用EasyTrain生成代码然后训练。MMEdU的图像分类

模块（MMeduCls）支持的算法有LeNet、MobileNet、ResNet18、ResNet50等。不同的算法适合不同的任务，比如LeNet适用于灰度图像。训练结束后会自动提示“是否转换为ONNX模型”。





2) 大模型方式

向大模型“咨询”搭建卷积神经网络训练图像分类模型，需要明确使用哪一种开发框架，如Keras或者PaddlePaddle，最好也能确认使用哪一种SOTA模型。同时需要指定数据集的格式和路径，以及分类的数量，尽可能确保生成的代码可以直接使用。当发现代码运行报错，要将错误信息发给大模型。大模型会根据错误反馈重新给出新的代码。

我想用PaddlePaddle来训练一个图片分类的模型，图片数据集为ImageNet格式，在“D:/mydataset”，里面有training_set和val_set两个文件夹。图片有3个类别需要区分。我希望用ResNet18的sota模型来实现，最后将文件保存到“D:/files”。

要使用PaddlePaddle来训练一个基于ImageNet数据集格式的图片分类模型，并且采用ResNet18作为骨干网络，你可以按照以下步骤进行：

1. 准备环境：

确保你已经安装了PaddlePaddle及其相关的库，比如 `paddlevision`（如果有的话）或者 `paddle.vision.transforms` 用于数据预处理。

2. 加载数据集：

使用 `paddle.io.Dataset` 或者 `paddle.vision.datasets`（如果PaddlePaddle提供了相应的实现）来加载你的数据集。但是，由于 `paddle.vision.datasets` 通常只包含预定义的数据集（如CIFAR10, MNIST等），你可能需要自己编写一个继承自 `paddle.io.Dataset` 的类来加载你的ImageNet格式的数据集。

3. 数据预处理：

定义数据预处理步骤，如缩放、裁剪、归一化等。可以使用 `paddle.vision.transforms` 来完成这些操作。

4. 构建模型：

```
26
27 # 构建ResNet18模型（这里需要你自己实现ResNet18的实现）
28 # model = paddle.vision.models.resnet18(num_classes=3) # 假设PaddlePaddle有这样的API,
29 # ... 或者你需要手动实现ResNet18
30
31 # 配置优化器和损失函数
32 optimizer = Momentum(parameters=model.parameters(), learning_rate=0.01, momentum=0.9)
33 loss_fn = CrossEntropyLoss()
34 metric = Accuracy()
35
36 # 训练循环（这里省略了详细实现）
37 # ...
38
39 # 保存模型
40 paddle.save(model.state_dict(), 'D:/files/resnet18_model.pdparams')
```

请注意，上述代码是一个简化的框架，用于指导你如何编写实际的代码。你需要根据自己的需求和数据集的具体情况来填充和完善这个框架。特别是加载数据集和构建ResNet18模型的部分，需要你自行编写或找到相应的实现。

由文心大模型 3.5 生成



我还没有安装相关的python环境怎么办，需要如何操作



如果您还没有安装Python环境，可以按照以下步骤来安装并配置一个适用于PaddlePaddle的Python环境：

1. 下载Python安装程序：

- 访问Python的官方网站 (<https://www.python.org/downloads/>) 来下载适用于您操作系统的Python安装程序。建议选择Python 3.x版本，因为PaddlePaddle通常支持较新的Python版本。

2. 安装Python：

- 双击下载的安装程序，并按照屏幕上的提示进行安装。在安装过程中，确保选择“将Python添加到PATH”选项（如果有的话），这样您就可以在系统任何位置运行Python命令。

3. 验证Python安装：

- 打开命令提示符（在Windows上）或终端（在macOS或Linux上）。
- 输入 `python --version` 或 `python3 --version`（取决于您的操作系统和Python安装）来检查Python是否已正确安装并显示版本号。

4. 安装PaddlePaddle：

- 由于PaddlePaddle是一个Python库，您需要使用pip（Python的包管理工具）来安装它。在命令提示符

4.目标检测模型的训练

1) EasyTrain方式

目标检测模型的训练和图像分类模型训练几乎一致，区别在于数据集的格式。MMEdU的目标检测任务选择coco数据集作为目标检测数据集的标准格式，如果手头的数据集是另一种格式（如VOC、yolo），需要使用类似BaseDT之类的工具来转换。



2) 大模型方式

向大模型“咨询”目标检测模型的训练代码，需要明确数据格式、数据集存放路径、检测几个类别的目标以及具体的目标名称等。



XEdu小助手

用户5952056511863 @f... | 发布于 2024-04-22 18:18

我想要训练一个MMDet的目标检测模型，数据格式为coco，存放在“D:/dataset”，只需要检测一个类别的目标，类别名称为plate。我希望使用一种sota模型来实现，请帮我写出代码。



XEdu小助手

根据您提供的信息，如果您想要使用MMEdu的MMDetection模块来训练目标检测模型，并且数据格式为COCO，存储路径在 `D:/dataset`，只用于检测名为 `plate` 的类别，您可以使用以下的代码片段来开始训练。这里我们将使用一个假设的SOTA模型，因为在提问中您没有具体指定一个明确的SOTA模型名称，我们可以认为 `SSD_Lite` 就是这种情况下合适的选择。

python

Copy

```
from MMEdu import MMDetection as det

# 实例化模型，这里我们选择了SSD_Lite模型
model = det(backbone='SSD_Lite')
```



三、附录

1.基于“扣子”的“XEdu小助手”

https://www.coze.cn/store/bot/7360618804000473128?bot_id=true

2.EasyTrain介绍文档

<https://xedu.readthedocs.io/zh/master/easydl/easytrain.html>

3.文心一言

<https://yiyao.baidu.com/>

4.智谱清言

<https://chatglm.cn/>

5.Kimi（月之暗面）

<https://kimi.moonshot.cn/>

6.讯飞星火

<https://xinghuo.xfyun.cn/desk>

7.通义千问

<https://tongyi.aliyun.com/qianwen/>